

Arquitectura de infraestructura para monitoreo de telemetría ambiental en ríos mediante procesamiento paralelo y contenedores Docker

Dylan Novoa

Universidad Tecnológica Metropolitana
Ingeniería Civil en Ciencia de Datos
INFB6074 Infraestructura para Ciencia de Datos
2026

Índice

1. Contexto y problema	3
2. Necesidad de datos	3
2.1. Variables consideradas	3
2.2. Características de los datos	4
3. Pregunta y propósito técnico	4
3.1. Pregunta técnica	4
3.2. Objetivo general	4
3.3. Objetivos específicos	4
4. Arquitectura preliminar	4
4.1. Flujo general	5
4.2. Componentes principales	5
5. Alternativas consideradas	5
5.1. Arquitectura monolítica	5
5.2. Arquitectura basada en microservicios con Docker	5
5.3. Infraestructura distribuida tipo Big Data	5
6. Criterios de evaluación	6
7. Prototipo o validación inicial	6
8. Riesgos y restricciones	6
9. Conclusión técnica	6

1. Contexto y problema

La contaminación hídrica representa uno de los principales problemas ambientales actuales debido a la presencia de residuos industriales, variaciones térmicas, alteraciones químicas y contaminación orgánica en cuerpos de agua.

En muchos casos, el monitoreo de ríos se realiza mediante mediciones manuales o sistemas poco automatizados, dificultando la detección temprana de anomalías ambientales. La ausencia de monitoreo continuo limita la capacidad de respuesta frente a eventos críticos como:

- Aumentos bruscos de temperatura.
- Cambios de pH.
- Incremento de turbidez.
- Disminución de oxígeno disuelto.
- Descargas contaminantes.

El presente anteproyecto propone el diseño de una infraestructura orientada a ciencia de datos capaz de recibir, almacenar y procesar telemetría ambiental proveniente de sensores distribuidos en distintos puntos de un río. La propuesta busca construir una arquitectura reproducible y escalable utilizando contenedores Docker y procesamiento paralelo para el análisis concurrente de flujos de datos ambientales.

2. Necesidad de datos

Debido a limitaciones de acceso a sensores físicos reales, el proyecto considera inicialmente una simulación de telemetría IoT basada en rangos ambientales obtenidos desde datasets públicos y documentación técnica.

2.1. Variables consideradas

Variable	Propósito
Temperatura del agua	Detección de anomalías térmicas
pH	Identificación de acidez o alcalinidad
Turbidez	Detección de partículas contaminantes
Oxígeno disuelto	Evaluación de salud ecosistémica
Conductividad	Presencia de minerales o químicos
Timestamp	Análisis temporal de eventos
Ubicación geográfica	Distribución espacial de sensores

Cuadro 1: Variables ambientales consideradas

2.2. Características de los datos

Característica	Descripción
Volumen	Cientos o miles de registros por hora
Velocidad	Flujo continuo de datos en tiempo real
Variedad	Diferentes métricas ambientales
Calidad	Posibles datos faltantes o ruido
Persistencia	Almacenamiento histórico para análisis
Restricciones	Recursos computacionales limitados

Cuadro 2: Características de los datos telemétricos

3. Pregunta y propósito técnico

3.1. Pregunta técnica

¿Cómo diseñar una infraestructura reproducible y escalable capaz de procesar telemetría ambiental de ríos en tiempo real utilizando contenedores y procesamiento paralelo para apoyar la detección temprana de anomalías ambientales?

3.2. Objetivo general

Diseñar una arquitectura de infraestructura para ciencia de datos orientada al procesamiento de telemetría ambiental de ríos mediante técnicas de procesamiento paralelo y contenedores Docker.


3.3. Objetivos específicos

- Simular una red de sensores IoT ambientales.
- Implementar un sistema de ingesta de datos mediante MQTT.
- Procesar telemetría concurrentemente utilizando paralelismo.
- Almacenar datos históricos en formato columnar.
- Visualizar métricas ambientales en un dashboard.

4. Arquitectura preliminar

La arquitectura propuesta se basa en un pipeline desacoplado de procesamiento de datos.

4.1. Flujo general



4.2. Componentes principales

Componente	Función
Sensores simulados	Generación de telemetría ambiental
Broker MQTT	Comunicación de datos en tiempo real
Procesamiento paralelo	Análisis concurrente de datos
Almacenamiento Parquet	Persistencia eficiente de datos
Docker	Reproducibilidad y despliegue
Dashboard	Visualización y monitoreo

Cuadro 3: Componentes de la arquitectura

5. Alternativas consideradas

5.1. Arquitectura monolítica

- Todo el procesamiento ocurre en una sola aplicación.
- Baja complejidad inicial, pero escalabilidad limitada y menor mantenibilidad.

5.2. Arquitectura basada en microservicios con Docker

- Servicios desacoplados con mejor mantenibilidad y escalabilidad moderada.
- Reproducibilidad mediante contenedores.

Esta alternativa fue seleccionada por su equilibrio entre complejidad y viabilidad para el alcance del curso.

5.3. Infraestructura distribuida tipo Big Data

- Uso de Spark y Kubernetes. Alta escalabilidad, pero mayor complejidad operativa.

Esta opción fue descartada debido al tiempo disponible y alcance académico.

6. Criterios de evaluación

Criterio	Forma de evaluación
Rendimiento	Tiempo de procesamiento de telemetría
Escalabilidad	Incremento de sensores simulados
Reproducibilidad	Despliegue mediante Docker Compose
Mantenibilidad	Modularidad de servicios
Resiliencia	Recuperación ante fallos simples
Costo computacional	Uso moderado de recursos
Calidad de datos	Manejo de datos faltantes o ruido

Cuadro 4: Criterios de evaluación del sistema

7. Prototipo o validación inicial

Durante el desarrollo del curso se espera implementar un prototipo funcional compuesto por: un simulador de sensores IoT, broker MQTT en Docker, procesamiento paralelo básico, almacenamiento en Parquet y un dashboard simple.

El prototipo permitirá validar el flujo de datos, la comunicación entre servicios, la capacidad concurrente y la persistencia histórica.

8. Riesgos y restricciones

Riesgo	Impacto
Ausencia de sensores reales	Uso de simulación de telemetría
Limitaciones computacionales	Menor escalabilidad
Complejidad de herramientas	Curva de aprendizaje elevada
Tiempo limitado del curso	Reducción de alcance
Datos con ruido	Validación y limpieza necesaria

Cuadro 5: Riesgos y restricciones del proyecto

9. Conclusión técnica

La propuesta busca diseñar una infraestructura orientada a ciencia de datos capaz de procesar telemetría ambiental de ríos mediante procesamiento paralelo y Docker. Aborda problemas de monitoreo ambiental mediante un enfoque modular, reproducible y escalable, integrando conceptos de telemetría IoT, procesamiento paralelo y persistencia de datos.

10. Referencias

- Docker Documentation. Disponible en: <https://docs.docker.com>

- MQTT Version 5.0 Specification. OASIS Standard.
- Apache Parquet Documentation. Disponible en: <https://parquet.apache.org>
- Dask Documentation. Disponible en: <https://docs.dask.org>
- Streamlit / Grafana Documentation.
- Material de clases INFB6074 Infraestructura para Ciencia de Datos.
- fuente de referencias database: <https://iotdataset.com>
- funcionamiento de sensores lot: https://iquodigital.com/uncategorized/__trashed
- tranferencia de datos MQTT: <https://aws.amazon.com/es/what-is/mqtt>
- estructuracion de informe formato latex con agente de IA geminis